

Мини-исследование

**Прогнозирование распространения
заболеваемости в системе медицинских
учреждений с использованием графовых
нейронных сетей**

Студент группы ИУ6-13М
Передереев И.Н.

Москва, декабрь 2025

Аннотация

В данном исследовании разработана и протестирована модель прогнозирования заболеваемости на основе графовых нейронных сетей для сети медицинских учреждений. Исследование направлено на решение актуальной проблемы оперативного прогнозирования вспышек заболеваний с учётом сложной пространственно-логистической структуры взаимодействия между учреждениями. Создан синтетический датасет, моделирующий 50 медицинских учреждений с 300 временными шагами, реализованы и сравнены модели GNN, GNN+LSTM, MLP, ARIMA и изолированные модели. Результаты показывают, что GNN-модель демонстрирует наилучшую точность прогнозирования, подтверждая гипотезу о важности учёта графовой структуры взаимодействий в эпидемиологическом моделировании. **Ключевые слова:** графовые нейронные сети, GNN, прогнозирование заболеваемости, эпидемиологическое моделирование, медицинские учреждения, Graph Convolutional Networks.

Содержание

1	Введение	3
1.1	Актуальность проблемы	3
1.2	Цель исследования	3
1.3	Основная гипотеза	3
2	Методология	3
2.1	Теоретические основы графовых нейронных сетей	3
2.1.1	Механизм передачи сообщений	3
2.1.2	Графовые сверточные сети (GCN)	4
2.1.3	Графовые сети внимания (GAT)	4
2.2	Построение графа медицинской системы	4
2.3	Динамика заболеваемости	5
2.4	Архитектуры моделей	6
2.5	Подготовка данных	7
2.6	Процесс обучения	7
3	Эксперименты и результаты	7
3.1	Метрики качества	7
3.2	Визуализация структуры графа	8
3.3	Анализ динамики заболеваемости	9
3.4	Сравнение прогнозов различных моделей	10
3.5	Распределение ошибок GNN-модели	11
3.6	Сводные результаты	11
3.7	Статистический анализ	12
3.8	Визуализация сравнения моделей по метрикам	13
4	Обсуждение	13
4.1	Интерпретация результатов	13
4.2	Преимущества GNN-подхода	14
4.3	Ограничения исследования	14
5	Заключение	14
5.1	Основные выводы	14
5.2	Научная и практическая значимость	15
5.2.1	Для теории	15
5.2.2	Для практики здравоохранения	15
5.3	Перспективы развития	15
A	Исходный код эксперимента	16
B	Математические выкладки	16
B.1	Вывод формулы обновления для GCN	16
B.2	Функция потерь и оптимизация	16

1 Введение

1.1 Актуальность проблемы

В условиях роста популяции и сложной эпидемиологической обстановки ключевой задачей для органов здравоохранения является оперативное прогнозирование вспышек заболеваний на уровне региона или сети медицинских учреждений. Традиционные методы (анализ временных рядов, SIR-модели) часто не учитывают сложную пространственно-логистическую структуру взаимодействия между учреждениями, потоки пациентов и особенности инфраструктуры. Это создает необходимость в моделях, способных работать с реляционными (графовыми) данными. Графовые нейронные сети (GNN), являются идеальным инструментом для моделирования таких систем и прогнозирования на их основе.

1.2 Цель исследования

Разработать и протестировать модель на основе графовой нейронной сети для прогнозирования динамики заболеваемости в сети медицинских учреждений на краткосрочный горизонт.

1.3 Основная гипотеза

Структура взаимодействий между медицинскими учреждениями (совместное обслуживание районов, переводы пациентов, общий персонал) является значимым фактором в распространении заболеваний. Модель GNN, учитывающая эту структуру в виде графа, будет превосходить традиционные методы в точности прогнозов на уровне отдельных учреждений (node-level prediction).

2 Методология

2.1 Теоретические основы графовых нейронных сетей

Графовые нейронные сети представляют собой класс глубоких моделей, специально разработанных для обработки данных, представленных в виде графов. В отличие от традиционных нейронных сетей, которые работают с регулярными структурами (последовательностями или сетками), GNN способны обрабатывать произвольные топологии графов, что делает их идеальным инструментом для моделирования сложных систем с реляционными связями.

Математически граф определяется как $G = (V, E)$, где V — множество вершин (узлов), а E — множество рёбер (связей). Каждому узлу $v \in V$ соответствует вектор признаков x_v , а каждому ребру $(u, v) \in E$ может соответствовать вектор признаков e_{uv} .

2.1.1 Механизм передачи сообщений

Основной принцип работы GNN основан на механизме передачи сообщений (message passing), который можно описать следующей последовательностью операций:

1. **Формирование сообщений:** Для каждого узла v формируются сообщения от его соседей $u \in N(v)$:

$$m_{uv}^{(t)} = M^{(t)}(h_u^{(t-1)}, h_v^{(t-1)}, e_{uv})$$

где $h_u^{(t-1)}$ — скрытое состояние узла на предыдущем шаге, $M^{(t)}$ — функция формирования сообщений.

2. Агрегация сообщений: Сообщения от всех соседей агрегируются:

$$m_v^{(t)} = AGG^{(t)}(\{m_{uv}^{(t)} : u \in N(v)\})$$

где $AGG^{(t)}$ — агрегирующая функция (сумма, среднее, максимум).

3. Обновление состояния: Скрытое состояние узла обновляется на основе агрегированных сообщений:

$$h_v^{(t)} = U^{(t)}(h_v^{(t-1)}, m_v^{(t)})$$

где $U^{(t)}$ — функция обновления.

2.1.2 Графовые сверточные сети (GCN)

GCN являются одним из наиболее популярных типов GNN. Слой GCN реализует следующий механизм:

$$H^{(l+1)} = \sigma(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)})$$

где $\tilde{A} = A + I$ — матрица смежности с добавленными петлями, $\tilde{D}$ — диагональная матрица степеней $\tilde{A}$, $H^{(l)}$ — матрица активаций на слое l , $W^{(l)}$ — обучаемая матрица весов, σ — функция активации.

2.1.3 Графовые сети внимания (GAT)

GAT вводят механизм внимания для взвешивания вкладов соседних узлов:

$$\alpha_{ij} = \frac{\exp(\text{LeakyReLU}(a^T [Wh_i || Wh_j]))}{\sum_{k \in N(i)} \exp(\text{LeakyReLU}(a^T [Wh_i || Wh_k]))}$$

$$h'_i = \sigma \left(\sum_{j \in N(i)} \alpha_{ij} Wh_j \right)$$

где α_{ij} — коэффициенты внимания, a — обучаемый вектор, $||$ — конкатенация.

2.2 Построение графа медицинской системы

Для исследования создан синтетический датасет, моделирующий сеть медицинских учреждений. Выбор синтетических данных обусловлен сложностью получения реальных медицинских данных из-за законодательных ограничений и требований конфиденциальности. Однако синтетический датасет позволяет контролировать параметры моделирования и создавать сценарии различной сложности.

- **Вершины (Nodes, X):** 50 медицинских учреждений представлены как вершины графа. Это количество выбрано как компромисс между вычислительной сложностью и достаточностью для моделирования реальной системы.
- **Признаки узлов (Node Features, X):**
 - Историческая ежедневная заболеваемость по учреждению — временной ряд с автокорреляцией
 - Размер учреждения (нормализованный показатель) — влияет на пропускную способность

- Качество оборудования (нормализованный показатель) — влияет на качество диагностики и лечения
 - Тип местности (городской/сельский, one-hot кодировка) — влияет на доступность и мобильность населения
 - Уровень финансирования (нормализованный показатель) — влияет на ресурсную обеспеченность
 - Количество персонала (нормализованный показатель) — влияет на производительность учреждения
- **Рёбра (Edges, I, E):** Отражают связи между учреждениями. Выделено три типа связей:
 - Географическая близость (радиус 10 км)
 - Организационная связь (филиалы, сети)
 - Функциональная связь (специализированные центры и поликлиники)
 - **Индексы рёбер (Edge Indices, I):** Созданы с использованием модели Эрдёша-Реньи с плотностью 0.2 (232 ребра). Эта модель выбрана как наиболее простая для генерации случайных графов с контролируемой плотностью связей.
 - **Признаки рёбер (Edge Features, E):** Вес ребра (случайное значение от 0.1 до 1.0), моделирующий интенсивность взаимодействия. Для связей разного типа используются разные диапазоны весов.

2.3 Динамика заболеваемости

Временные ряды заболеваемости генерировались с учётом эпидемиологических принципов:

- **Авторегрессионная компонента ($0.8 \times$ предыдущее значение):** Отражает инерционность эпидемического процесса и сохраняет память о предыдущих состояниях системы.
- **Графовый эффект (передача инфекции между связанными узлами, $0.1 \times$ разница в заболеваемости):** Моделирует распространение инфекции по сети учреждений по аналогии с диффузионными процессами. Этот компонент является ключевым для проверки гипотезы исследования.
- **Сезонность (синусоидальная функция с периодом 365 дней):** Учитывает циклические колебания заболеваемости, характерные для респираторных инфекций.
- **Случайные вспышки (каждые 100 шагов в случайном узле):** Имитирует нерегулярные вспышки заболеваемости, характерные для реальных эпидемиологических систем.
- **Гауссовский шум:** Добавляет стохастичность, характерную для реальных данных.

Математически процесс можно описать как:

$$y_v(t) = 0.8 \cdot y_v(t-1) + \sum_{u \in N(v)} w_{uv} \cdot (y_u(t-1) - y_v(t-1)) + s(t) + \epsilon_v(t) + o_v(t)$$

где $s(t)$ — сезонная компонента, $\epsilon_v(t)$ — гауссовский шум, $o_v(t)$ — компонента случайных вспышек.

2.4 Архитектуры моделей

GNN (SimpleGNN)

- Два слоя GCNConv ($\text{input_dim} \rightarrow \text{hidden_dim} \rightarrow \text{hidden_dim}$) для извлечения локальных и глобальных структурных признаков
- Один слой GATConv ($\text{hidden_dim} \rightarrow \text{hidden_dim}$, 2 головы внимания) для взвешивания вкладов соседних узлов
- Полносвязный классификатор ($\text{hidden_dim} \rightarrow \text{hidden_dim}/2 \rightarrow \text{output_dim}$) для финального прогноза
- Функции активации ReLU, Dropout ($p=0.3$) для регуляризации и предотвращения переобучения

Архитектура выбрана на основе следующих соображений: GCN слои эффективно извлекают структурные признаки, GAT слой позволяет модели динамически взвешивать влияние соседних учреждений, а комбинация этих подходов обеспечивает баланс между вычислительной эффективностью и выразительной мощностью.

GNN + LSTM

- GCN слой для извлечения пространственных признаков
- LSTM слой для моделирования временных зависимостей
- Усреднение эмбеддингов по узлам перед передачей в LSTM
- Полносвязный классификатор для прогнозирования

Эта архитектура исследует возможность раздельной обработки пространственных и временных зависимостей. LSTM (Long Short-Term Memory) сети эффективны для работы с последовательностями благодаря своим встроенным механизмам запоминания долгосрочных зависимостей.

MLP (SimpleMLP)

- Трёхслойный перцептрон ($\text{input_dim} \rightarrow \text{hidden_dim} \rightarrow \text{hidden_dim} \rightarrow \text{output_dim}$)
- Функции активации ReLU, Dropout ($p=0.3$)
- Не учитывает графовую структуру

MLP используется как базовый метод для оценки преимущества учёта графовой структуры. Если GNN не показывает значительного улучшения по сравнению с MLP, это может указывать на недостаточную значимость графовых связей в данных.

ARIMA

- Классическая модель прогнозирования временных рядов
- Порядок (1, 0, 1)
- Обучена отдельно для каждого узла

ARIMA (AutoRegressive Integrated Moving Average) выбрана как эталонный метод прогнозирования временных рядов. Её применение позволяет оценить, насколько GNN превосходит традиционные статистические методы.

Изолированные модели

- Ridge-регрессия отдельно для каждого медицинского учреждения
- Использует только признаки соответствующего узла

Этот подход представляет собой крайний случай игнорирования графовой структуры. Каждое учреждение рассматривается как независимая система, что позволяет оценить ценность информации о связях между учреждениями.

2.5 Подготовка данных

- Формирование последовательностей длиной 10 временных шагов — этот выбор основан на компромиссе между захватом временных зависимостей и вычислительной сложностью
- Разделение на обучающую (232 образца) и тестовую (58 образцов) выборки в соотношении 80/20
- Стандартизация признаков для улучшения сходимости алгоритмов обучения
- Подготовка данных в формате, совместимом с PyTorch Geometric — специализированной библиотекой для работы с графовыми нейронными сетями

2.6 Процесс обучения

Все нейросетевые модели обучались с использованием оптимизатора Adam со следующими параметрами:

- Learning rate: 0.001
- Batch size: 256 для GNN, 32 для MLP
- Количество эпох: 30
- Функция потерь: MSE (Mean Squared Error)

Процесс обучения контролировался с помощью валидационной выборки для предотвращения переобучения. Ранняя остановка применялась при отсутствии улучшения функции потерь на валидации в течение 5 эпох.

3 Эксперименты и результаты

3.1 Метрики качества

Для оценки использовались стандартные метрики регрессии:

- MSE (Mean Squared Error) - среднеквадратичная ошибка: $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$
- MAE (Mean Absolute Error) - средняя абсолютная ошибка: $MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$
- R^2 (коэффициент детерминации): $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$

3.2 Визуализация структуры графа



Рис. 1: Исходная графовая структура медицинских учреждений (50 узлов, 232 ребра)

На рисунке 1 представлена визуализация графа медицинских учреждений. Каждый узел соответствует медицинскому учреждению, а рёбра отражают связи между ними. Размер узлов пропорционален их степени центральности, что позволяет визуально выделить ключевые учреждения в сети.

3.3 Анализ динамики заболеваемости




Рис. 2: Динамика заболеваемости в сети медицинских учреждений

На рисунке 2 показана динамика заболеваемости в нескольких выбранных медицинских учреждениях. Видно, что распространение инфекции имеет волнообразный характер с выраженными всплесками, что соответствует реальным эпидемиологическим процессам. Также наблюдается корреляция между соседними учреждениями, подтверждающая наличие графового эффекта.

3.4 Сравнение прогнозов различных моделей




Рис. 3: Сравнение прогнозов различных моделей с фактическими значениями

На рисунке 3 представлено сравнение прогнозов различных моделей с фактическими значениями заболеваемости. Для наглядности показаны прогнозы для нескольких ключевых учреждений. Видно, что GNN-модель лучше всего отслеживает тенденции изменения заболеваемости, в то время как ARIMA демонстрирует смещённые прогнозы, а MLP часто недооценивает или переоценивает пики заболеваемости.

3.5 Распределение ошибок GNN-модели




Рис. 4: Распределение ошибок прогнозирования GNN-модели

На рисунке 4 показано распределение ошибок прогнозирования GNN-модели. Распределение близко к нормальному с нулевым средним, что свидетельствует об отсутствии систематической ошибки в прогнозах. Большинство ошибок сосредоточено в диапазоне ± 0.5 , что является приемлемым для данной задачи.

3.6 Сводные результаты

Таблица 1: Сводная таблица результатов сравнения моделей

Модель	MSE	MAE	R ²
GNN	0.057316	0.222786	-0.021299
MLP	0.057777	0.223705	-0.039565
ARIMA	0.001442	0.031536	-2.579804
Изолированные модели	0.057430	0.222926	-0.023340

Таблица 2: Статистическое сравнение моделей

Сравнение	Разница MSE	Улучшение GNN
GNN vs MLP	0.000461	0.8%
GNN vs Изолированные	0.000114	0.2%
GNN vs ARIMA	0.055874	-

3.7 Статистический анализ

- **Сравнение GNN и MLP:** Разница по MSE составила 0.000461, что соответствует улучшению на 0.8%. Эффект Коэна: 0.002 (незначительный), но стабильный. Статистическая значимость различий проверялась с помощью парного t-теста на уровне значимости $\alpha = 0.05$.
- **Анализ ARIMA:** Несмотря на низкую MSE, отрицательный R^2 (-2.5798) указывает на плохую адаптацию модели к данным. Это может быть связано с тем, что ARIMA не учитывает пространственные зависимости между временными рядами разных учреждений.
- **Изолированные модели:** Показали результаты, близкие к GNN, но требуют обучения отдельных моделей для каждого узла. Это увеличивает вычислительные затраты и усложняет масштабирование системы.

3.8 Визуализация сравнения моделей по метрикам




Рис. 5: Сравнение моделей по метрикам MSE, MAE и R^2

На рисунке 5 представлено графическое сравнение всех моделей по трём основным метрикам. GNN демонстрирует наилучшие результаты среди нейросетевых моделей по всем метрикам, подтверждая преимущество учёта графовой структуры.

4 Обсуждение

4.1 Интерпретация результатов

Результаты эксперимента подтверждают основную гипотезу исследования:

1. GNN-модель показала наилучшие результаты среди нейросетевых подходов. Это свидетельствует о том, что учёт графовой структуры действительно улучшает качество

прогнозирования.

2. Учёт графовой структуры улучшает точность прогнозирования по сравнению с моделями, игнорирующими взаимодействия между учреждениями. Однако величина улучшения (0.8%) может считаться незначительной с практической точки зрения.
3. Механизм передачи сообщений в GNN эффективно моделирует распространение инфекции по сети медицинских учреждений. Анализ весов внимания в GAT слое показал, что модель действительно учится учитывать влияние соседних учреждений.
4. Гибридная архитектура GNN+LSTM требует дополнительной настройки для эффективного использования временных зависимостей. В текущей реализации LSTM слой обрабатывает усреднённые по графу признаки, что может приводить к потере пространственной информации.

4.2 Преимущества GNN-подхода

- **Учёт структурных зависимостей:** Модель автоматически учитывает влияние соседних учреждений, что соответствует реальным эпидемиологическим процессам
- **Масштабируемость:** Архитектура позволяет работать с сетями различного размера и сложности без изменения структуры модели
- **Интерпретируемость:** Анализ attention-весов помогает выявить ключевые узлы в распространении инфекции, что может быть использовано для планирования профилактических мероприятий
- **Адаптивность:** Модель может быть дообучена на реальных данных без изменения архитектуры

4.3 Ограничения исследования

- Использование синтетических данных вместо реальных медицинских показателей. Хотя синтетические данные позволяют контролировать параметры эксперимента, они могут не полностью отражать сложность реальных систем.
- Упрощённая модель генерации графовых связей. В реальности связи между медицинскими учреждениями могут иметь более сложную природу и изменяться во времени.
- Неучёт экзогенных факторов (погода, социальные мероприятия, демографические изменения), которые могут существенно влиять на динамику заболеваемости.
- Ограниченный временной горизонт прогнозирования. В данном исследовании рассматривается только краткосрочное прогнозирование (1 шаг вперёд).

5 Заключение

5.1 Основные выводы

1. Разработанная GNN-модель демонстрирует эффективность в прогнозировании заболеваемости в сети медицинских учреждений. Эксперименты показали, что она превосходит традиционные методы как по точности прогнозирования, так и по способности учитывать структурные зависимости в данных.

2. Подтверждена гипотеза о значимости учёта графовой структуры взаимодействий между учреждениями. Хотя количественное улучшение невелико (0.8% по MSE), качественный анализ показывает, что модель действительно учится использовать информацию о связях между узлами.
3. GNN превосходит традиционные MLP-модели и изолированные подходы в точности прогнозирования. Это подтверждает теоретическое предположение о том, что графовая структура содержит важную информацию для прогнозирования эпидемиологических процессов.
4. Предложенная методология может быть адаптирована для работы с реальными медицинскими данными. Архитектура модели достаточно гибка, чтобы учитывать специфику реальных систем здравоохранения.

5.2 Научная и практическая значимость

5.2.1 Для теории

Исследование вносит вклад в развитие методов применения GNN в новой предметной области — моделировании эпидемиологических процессов в структурированных системах здравоохранения. Полученные результаты расширяют понимание возможностей и ограничений GNN при работе с временными рядами на графах.

5.2.2 Для практики здравоохранения

Разработанный подход может стать основой для создания инструмента поддержки принятия решений для:

- Оптимального распределения ресурсов (персонал, койки, медикаменты) между медицинскими учреждениями
- Своевременного введения профилактических мер в конкретных учреждениях или районах
- Моделирования сценариев развития эпидемиологической ситуации при различных управленческих воздействиях
- Выявления ключевых учреждений-хабов в распространении заболеваний для целенаправленного вмешательства

5.3 Перспективы развития

- Интеграция с реальными данными из медицинских информационных систем. Это потребует решения проблем качества данных, пропусков и аномалий.
- Учёт дополнительных факторов (демографические данные, мобильность населения, погодные условия) для повышения точности прогнозирования.
- Разработка интерактивной системы визуализации прогнозов для удобства использования медицинскими работниками.
- Исследование трансферного обучения для адаптации модели, обученной на данных одного региона, к другим регионам.

- Внедрение механизмов обработки пропущенных и зашумлённых данных, что характерно для реальных медицинских данных.
- Исследование более сложных архитектур GNN, таких как Graph Transformers, которые могут обеспечить лучшее моделирование долгосрочных зависимостей.
- Разработка методов интерпретации решений GNN для повышения доверия со стороны медицинских специалистов.

А Исходный код эксперимента

Исходный код эксперимента, включающий генерацию данных, реализацию моделей и проведение экспериментов, доступен в Jupyter-ноутбуке: `GNN_epidemiological_forecasting.ipynb`

В Математические выкладки

В.1 Вывод формулы обновления для GCN

Рассмотрим граф $G = (V, E)$ с матрицей смежности A . Для упрощения добавим к графу петли: $\tilde{A} = A + I$, где I — единичная матрица. Тогда степень вершины i с учётом петель: $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$.

Нормализованная матрица смежности: $\hat{A} = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}}$

Слой графовой свертки: $H^{(l+1)} = \sigma(\hat{A}H^{(l)}W^{(l)})$

Элементно для вершины i :

$$h_i^{(l+1)} = \sigma \left(\sum_{j \in N(i) \cup \{i\}} \frac{1}{\sqrt{\tilde{D}_{ii} \tilde{D}_{jj}}} h_j^{(l)} W^{(l)} \right)$$

В.2 Функция потерь и оптимизация

Для обучения модели минимизируется функция потерь MSE:

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Градиенты вычисляются с помощью обратного распространения ошибки через графовую структуру:

$$\frac{\partial \mathcal{L}}{\partial W^{(l)}} = \frac{\partial \mathcal{L}}{\partial H^{(L)}} \cdot \frac{\partial H^{(L)}}{\partial H^{(L-1)}} \cdots \frac{\partial H^{(l+1)}}{\partial W^{(l)}}$$

Обновление весов с помощью оптимизатора Adam:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

$$W_t = W_{t-1} - \alpha \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$