

Поддержка принятия решений в системах мониторинга
«Анализ изображений для обнаружения дефектов поверхностей
различных конструкций на основе снижения размерности и
кластеризации»

Шумайлова А.Ю.

ИУ6-13М

2025 г.

Содержание

1	Введение	3
1.1	Постановка проблемы и цель исследования	3
1.2	Гипотеза	3
1.3	Задачи исследования	3
2	Обзор данных и методов	3
2.1	Выбор и описание набора данных	3
2.2	Используемые методы	4
2.2.1	Снижение размерности	4
2.2.2	Методы кластеризации	4
2.2.3	Метрика оценки качества кластеризации	5
3	Практическая часть	5
3.1	Предварительный анализ данных	5
3.2	Извлечение признаков	5
3.3	Проверка разделимости классов	6
3.4	Кластеризация	7
3.4.1	Кластеризация всего датасета	7
3.4.2	Исследование подклассов внутри трещин	7
4	Выводы	9
4.1	Гипотезы	9
4.2	Ограничения исследования	9
5	Заключение	9

1 Введение

1.1 Постановка проблемы и цель исследования

Исходная задача создания интеллектуальной системы для реконструкции архитектурных объектов требует, в качестве фундаментального этапа, точной диагностики текущего состояния поверхности. Целью данного исследовательского проекта является проверка гипотезы о возможности выявления значимых паттернов в изображениях поверхностей с помощью методов снижения размерности и неконтролируемого обучения, что составляет основу для последующего построения эффективных моделей поддержки принятия решений в системах мониторинга.

1.2 Гипотеза

Основная гипотеза: Методы снижения размерности и кластеризации позволяют выявить скрытые, статистически значимые факторы в пространстве признаков изображений, которые объективно разделяют состояния «поврежденная поверхность» и «неповрежденная поверхность». Эти факторы могут служить основой для построения эффективных признаков описаний в системах автоматического мониторинга.

Дополнительная гипотеза: Внутри однородной категории «поврежденная поверхность» существуют различные подтипы дефектов (например, различающиеся по морфологии или контрасту), которые образуют обособленные подкластеры в пространстве признаков и могут быть выявлены методами неконтролируемой кластеризации.

1.3 Задачи исследования

Для достижения поставленной цели в работе последовательно решаются следующие задачи:

- Выбор и предварительный анализ набора данных изображений поверхностей с повреждениями и без них.
- Проведение разведочного анализа данных для оценки статистических различий между классами и визуального понимания природы дефектов.
- Разработка и применение конвейера для извлечения информативных признаков, преобразующих изображения в формат, пригодный для алгоритмов.
- Применение методов снижения размерности (PCA, t-SNE) для анализа структуры данных, визуализации и проверки разделимости основных классов.
- Проверка возможности выделения устойчивых подклассов внутри категории поврежденных изображений с помощью алгоритмов кластеризации.
- Количественная оценка и содержательная интерпретация полученных результатов, формулировка выводов о подтверждении или опровержении выдвинутых гипотез.

2 Обзор данных и методов

2.1 Выбор и описание набора данных

Для исследования использовался публичный датасет [Surface Crack Detection](#), размещенный на платформе Kaggle. Его выбор обусловлен следующими ключевыми факторами:

- Данные полностью соответствуют задаче визуального мониторинга состояния поверхностей конструкций.
- Набор предварительно очищен, размечен (бинарная классификация: "Positive" – с трещиной, "Negative" – без трещины) и имеет единый размер 227×227 пикселей, что исключает трудоемкий этап предобработки.
- Содержит 40 000 изображений, равномерно распределенных по двум классам (по 20 000), что достаточно для статистической значимости и исключает проблему смещения модели.

Примеры исходных данных можно увидеть на рисунке 1.



Рис. 1: Примеры исходных данных

2.2 Используемые методы

2.2.1 Снижение размерности

- **Метод главных компонент (PCA – Principal Component Analysis):** Линейный метод, находящий новые ортогональные оси (главные компоненты) в данных, которые максимизируют сохраняемую дисперсию. Первая компонента соответствует направлению наибольшей изменчивости данных. Цель применения: 1) Резкое сокращение числа признаков (с 85 до 10-50) для снижения вычислительной сложности и "шума"; 2) Интерпретация: анализ весов в первых РС показывает, какие исходные признаки вносят наибольший вклад в разделение данных.
- **t-SNE (t-distributed Stochastic Neighbor Embedding):** Нелинейный метод, оптимизирующий представление данных в пространстве низкой размерности (обычно 2D) для сохранения локальных расстояний между точками. Цель применения: Визуальная качественная оценка структуры данных. Ожидаемый результат: Если признаки информативны, то на графике t-SNE изображения с трещинами и без них образуют визуально разделимые скопления (кластеры).

2.2.2 Методы кластеризации

- **Иерархическая агломеративная кластеризация (Agglomerative Clustering):** Алгоритм "снизу вверх" начинающий с того, что каждая точка является отдельным

кластером, и последовательно объединяющий наиболее близкие пары кластеров. Близость определяется выбранной метрикой расстояния и методом связи (linkage): ward (минимизация дисперсии), average, complete. Цель применения: 1) Проверка основной гипотезы: применив алгоритм ко всему датасету без учета меток, ожидаем получить разделение, близкое к исходным классам "трещина"/"нет трещины". 2) Исследование иерархической структуры данных с помощью дендрограммы.

- **K-Means:** Итеративный алгоритм, минимизирующий сумму квадратов расстояний от точек до центроидов их кластеров. Требуется априорного задания числа кластеров k . Цель применения: Используется в методе "локтя" (Elbow Method) для эмпирической оценки оптимального числа кластеров k по точке изгиба графика "инерция (within-cluster sum of squares) – k ".
- **DBSCAN (Density-Based Spatial Clustering):** Алгоритм, основанный на плотности, формирующий кластеры как области высокой плотности точек, разделенные областями низкой плотности. Выделяет выбросы (шум). Цель применения: Автоматическое обнаружение кластеров произвольной формы в данных о трещинах, без предположения об их сферичности или заранее заданном количестве.

2.2.3 Метрика оценки качества кластеризации

Силуэтный коэффициент (Silhouette Score): Оценивает, насколько похож объект на свой собственный кластер (когезия) по сравнению с другими кластерами (сепарация). Диапазон значений от -1 до 1. Интерпретация: Значения >0.5 указывают на сильную кластерную структуру, около 0 – на перекрывающиеся кластеры, <0 – на возможную неверную кластеризацию. Это основная метрика для сравнения методов и оценки разделимости.

3 Практическая часть

3.1 Предварительный анализ данных

Для выборки из 100 изображений каждого класса рассчитано распределение значений пикселей. Установлены статистически значимые различия между классами по средней яркости (175.7 для Negative vs 164.0 для Positive) и контрастности (стандартное отклонение: 11.1 для Negative vs 31.8 для Positive). Это количественно подтвердило визуальные наблюдения и обосновало возможность автоматического разделения.

3.2 Извлечение признаков

Для перехода от изображений к признаковому пространству была реализована функция, формирующая для каждого изображения вектор из 85 числовых дескрипторов, объединяющих:

- Статистику интенсивности (7 признаков).
- Текстурные признаки GLCM (72 признака, рассчитанные для 3 расстояний и 4 направлений).
- Признаки HOG (первые 20 компонент).
- Градиентные признаки (4 признака на основе фильтров Собеля).




Рис. 2: Этапы извлечения признаков

Для наглядности и отчета визуализируем процесс извлечения признаков на конкретном примере (Рис. 2)

Тепловая карта сравнения признаков представлена на рисунке 3.




Рис. 3: Тепловая карта сравнения признаков

Для дальнейшего анализа использовалась случайная сбалансированная выборка из 1000 изображений (500 на класс). Все признаки были стандартизированы.

3.3 Проверка разделимости классов

Для проверки гипотезы о наличии латентных факторов, разделяющих классы, применен конвейер $PCA \rightarrow t-SNE$.

РСА-анализ: К стандартизованным данным (85 признаков) применен РСА. Первые 3 главные компоненты объясняют 98% общей дисперсии данных, что указывает на высокую степень структурированности и возможность сильного сжатия информации (Рис. 4).

Для наглядности данные, сокращенные РСА до 10 компонент, были спроецированы на плоскость с помощью t-SNE (Рис. 5).

На графике t-SNE наблюдается четкое визуальное разделение двух компактных областей. Силуэтный коэффициент, рассчитанный для исходных меток классов в этом новом пространстве, составил 0.545, что интерпретируется как хорошее разделение.




Рис. 4: Определение главных компонент




Рис. 5: Визуализация

Вывод: основная гипотеза подтверждается. Методы снижения размерности выявили в данных устойчивую структуру, соответствующую состоянию объекта.

3.4 Кластеризация

3.4.1 Кластеризация всего датасета

Применение Agglomerative Clustering к данным после PCA выявило, что первое крупное разделение на 2 кластера практически полностью соответствует исходным классам. Это подтверждает, что выявленная PCA структура является объективной и воспроизводимой.

3.4.2 Исследование подклассов внутри трещин

Для независимой проверки структуры данных и исследования возможности выделения подклассов применен метод иерархической агломеративной кластеризации (Agglomerative Clustering) к данным всего датасета.

Выбор оптимального числа кластеров: На основе анализа дендрограммы (Рис. 6), отображающей иерархию слияний, был выбран уровень разделения, соответствующий 3 кластерам.




Рис. 6: Визуализация

Результат и интерпретация кластеров: **Кластер 0** (117 изображений, 98% трещин): Объединяет изображения с наиболее явными и контрастными трещинами. Этот вывод подтверждается самым высоким средним значением по первой главной компоненте ($PC1 = 848.21$), которая, как показал PCA-анализ, вносит наибольший вклад в дисперсию данных и сильно коррелирует с признаками контраста.

Кластер 1 (444 изображения, 3% трещин): Представляет собой практически чистые поверхности без повреждений. Доминирование этого класса в выборке соответствует сбалансированности исходного датасета.

Кластер 2 (275 изображений, 97% трещин): Включает изображения с менее выраженными или более тонкими трещинами. Среднее значение $PC1$ для этого кластера существенно ниже (269.66), чем у Кластера 0, что указывает на меньший визуальный контраст дефектов относительно фона.

Визуальная оценка: На графике t-SNE (Рис. 7) с раскраской по полученным кластерам видно, что Кластер 0 и Кластер 2 образуют два отдельных, хотя и близко расположенных, сгустка в области, соответствующей изображениям с трещинами. Это подтверждает наличие внутренней неоднородности внутри категории повреждений.




Рис. 7: Выделенные подклассы

Вывод: Результаты кластеризации частично подтверждают дополнительную гипотезу. Метод Agglomerative Clustering выявил два статистически обособленных подкласса внутри изображений с трещинами, которые интерпретируются как "явные/контрастные трещины" и "слабые/низкоконтрастные трещины". Это разделение в первую очередь опре-

деляется значениями первой главной компоненты (PC1), являющейся интегрированной мерой визуальной выраженности дефекта. Наличие подобной градации имеет практическое значение для систем мониторинга, так как позволяет не только детектировать факт повреждения, но и проводить первичную оценку его серьезности.

4 Выводы

4.1 Гипотезы

Основная гипотеза подтвердилась полностью. Методы снижения размерности и кластеризации успешно выявили фундаментальные латентные факторы, лежащие в основе различия между повреждённым и неповреждённым состоянием бетонных поверхностей.

Дополнительная гипотеза подтвердилась частично. Внутри категории "трещины" были обнаружены признаки внутренней структуры, однако не в виде множества подклассов, а в виде градации по степени выраженности. Agglomerative Clustering выделил два устойчивых подкласса повреждений, интерпретируемых как: кластер "Явные/контрастные трещины" (высокие значения PC1) и кластер "Слабые/низкоконтрастные трещины" (средние значения PC1). Это разделение, выявленное на всём датасете, указывает на существование непрерывного спектра повреждений, который алгоритм разбил на две наиболее однородные группы, что имеет ценность для приоритизации.

4.2 Ограничения исследования

Несмотря на достигнутые результаты, работа имеет ряд ограничений, определяющих границы применимости выводов. Наиболее весомое ограничение - исследование проводилось на одном конкретном датасете. Результаты могут не обобщаться на данные, полученные в принципиально иных условиях (например, с дронов или при другом освещении).

Методологическое ограничение: Выбор числа кластеров в Agglomerative Clustering, несмотря на опору на дендрограмму, частично остается субъективным решением исследователя. Альтернативные методы (например, DBSCAN) показали низкое качество на этих данных.

5 Заключение

В рамках данного исследовательского проекта был успешно реализован и протестирован конвейер анализа изображений поверхностей на основе методов снижения размерности и кластеризации. Работа подтвердила, что данный подход позволяет не только эффективно отделять повреждённые поверхности от неповреждённых, выявляя скрытые, но статистически значимые паттерны, но и проводить внутреннюю градацию трещин по степени их визуальной выраженности. Таким образом, достигнута основная цель исследования — доказана принципиальная возможность и практическая целесообразность использования предложенного набора методов для решения задач автоматизированного мониторинга состояния строительных конструкций, что формирует прочную основу для разработки более сложных и специализированных диагностических систем.

Список литературы

- [1] Учебные материалы лекций.

[2] Kaggle: Surface Crack Detection Dataset.