

Исследовательский проект

Прогнозирование занятости парковки на основе анализа временных рядов

Группа ИУ6-13М, Варняга М.О.

Аннотация

В данной работе проведено исследование по прогнозированию занятости парковки для сервиса Parkovich, который является умный сервисов для поиска свободных парковочных мест. С помощью Parkovich водитель может в режиме реального времени видеть свободные места на парковках, а с помощью будущей функции прогнозирования свободных мест водитель будет заранее знать, насколько будет заполнена парковка в любой час суток. На основе синтетических данных, моделирующих поведение парковки в жилой зоне, проведён комплексный анализ временных рядов, включая кластеризацию суточных профилей занятости, оценку значимости признаков и построение системы прогнозирования. Результаты показывают возможность эффективного предсказания уровня загрузки парковки с учётом временных, погодных и поведенческих факторов.

Дата: 16 декабря 2025 г.

Содержание

1	Введение	2
2	Генерация синтетических данных	2
2.1	Принципы генерации синтетического датасета	2
2.2	Структура данных	3
3	Предварительный анализ данных	3
3.1	Статистическая характеристика датасета	3
3.2	Визуализационное исследование	3
4	Кластеризация временных рядов	5
4.1	Методологический подход	5
4.2	Результаты кластеризации	6
5	Анализ характеристик кластеров	7
5.1	Профили занятости	7
5.2	Метаданные кластеров (рисунок 6)	9
6	Анализ значимости признаков	10
6.1	Методология оценки	10
6.2	Результаты анализа	11
7	Система прогнозирования и тестирование	11
7.1	Архитектура системы прогнозирования	11
7.2	Механизм классификации: взвешенная схема сравнения	12
7.3	Генерация почасового прогноза	13
8	Заключение	14

1 Введение

Умный сервис Parkovich предоставляет пользователям информацию о доступности парковочных мест в реальном времени, что позволяет водителям сэкономить своё время, силы и нервы. Для улучшения пользовательского опыта требуется разработка функции прогнозирования загрузки парковок, позволяющей пользователям планировать свои поездки. В данном исследовании решается задача прогнозирования занятости парковки на основе анализа временных рядов с использованием методов машинного обучения без учителя.

2 Генерация синтетических данных

2.1 Принципы генерации синтетического датасета

Для моделирования реалистичного поведения парковки в жилой зоне разработан специализированный генератор данных, учитывающий следующие аспекты:

Временные паттерны:

- Базовые суточные профили разделены на будние и выходные дни
- Учтены сезонные колебания (летний спад из-за отпусков, зимний рост)
- Интегрирован официальный календарь праздников России 2024 года
- Реализованы специфические эффекты (пятничные вечера, понедельничные утра)

Факторные влияния:

- Погодные условия с региональной привязкой к климату Москвы
- Температурные воздействия с различной чувствительностью для разных типов погоды
- Поведенческие метрики (просмотры в мобильном приложении) с временными лагами

Реалистичность модели:

- Использование вероятностных распределений для генерации погодных условий
- Введение умеренного гауссовского шума для имитации случайных колебаний
- Корреляция между просмотрами в приложении и последующей занятостью

- Дискретизация результатов до целых чисел занятых мест

2.2 Структура данных

Сгенерированный датасет содержит почасовые наблюдения за полный год (8760 записей) со следующими группами признаков:

- **Временные метрики:** час, день недели, месяц, праздничные флаги
- **Погодные характеристики:** тип погоды, температура
- **Поведенческие индикаторы:** просмотры в приложении, лагированные значения
- **Целевые переменные:** процент занятости парковки

3 Предварительный анализ данных

3.1 Статистическая характеристика датасета

Первичный анализ выявил полную заполненность данных (отсутствие пропусков и дубликатов). Распределение целевой переменной (процент занятости) демонстрирует близость к нормальному распределению.

3.2 Визуализационное исследование

Перед тем, чтобы начать решать общую поставленную задачу, нужно понять, как именно синтезировался датасет, всё ли корректно. Построен комплекс графиков для понимания структуры данных (рисунки 1-2).

Распределения признаков:

- Гистограмма занятости показывает бимодальное распределение с пиками в зонах низкой и высокой загрузки
- Температурное распределение соответствует сезонным ожиданиям для Москвы
- Частотность погодных условий отражает климатические особенности региона

Временные паттерны:

- Суточные профили чётко разделяются на будничные (с выраженным дневным спадом) и выходные (с относительно равномерной высокой загрузкой)

- Недельные циклы показывают повторяемость паттернов
- Годовая динамика демонстрирует сезонные колебания с пиками в холодный период

Факторный анализ:

- Погодные условия также влияют на занятость (особенно, эффект у снега и дождя)
- Корреляция просмотров в приложении с занятостью имеет нелинейный характер со слабой линейной составляющей




Рис. 1: Аналитические графики занятости парковки




Рис. 2: Распределения основных показателей

4 Кластеризация временных рядов

4.1 Методологический подход

Для выявления типовых суточных паттернов занятости применена кластеризация методом K-means. Ключевые особенности подхода:

Препроцессинг временных рядов:

- Преобразование почасовых данных в суточные профили (24 измерения)
- Интерполяция пропущенных значений линейным методом (в случае подставления реального датасета вместо синтезированного)
- Стандартизация признаков для фокусировки на форме профилей, а не абсолютных значениях

Оптимизация числа кластеров:

Изначально сложно сказать, сколько кластеров должно получиться. Поэтому было принято решение комбинированного использования трёх методов:

- Метод локтя (Elbow method) для анализа снижения инерции

- Силуэтный анализ (Silhouette analysis) для оценки разделимости кластеров
- Индекс Дэвиса-Боулдина (Davies-Bouldin index) для минимизации внутрикластерного расстояния при максимизации межкластерного

Результат применения данных методов показан на рисунке 3.



Рис. 3: Определение оптимального количества кластеров

Из рисунка 3 наглядно видно, что оптимальное число кластеров равно 4.

Валидация результатов:

- Визуальная оценка центроидов кластеров
- Проекция в пониженную размерность методом главных компонент (РСА)

4.2 Результаты кластеризации

Оптимальным признано разделение на 4 кластера с силуэтным коэффициентом 0.420, что указывает на умеренное, но значимое разделение. Полученные кластеры (рисунок 4) распределились следующим образом:

- Кластер 0: 17.3% дней (63 дня)
- Кластер 1: 50.1% дней (183 дня)
- Кластер 2: 24.9% дней (91 день)
- Кластер 3: 7.7% дней (28 дней)




Рис. 4: Кластеризация временных рядов (РСА проекция)

Из рисунка 4 наблюдается четкое разделение временных рядов на 4 кластера.

5 Анализ характеристик кластеров

5.1 Профили занятости

Каждый кластер характеризуется уникальным суточным профилем (рисунок 5):

Кластер 0 (средняя загрузка):

- Средняя занятость: 56.4%
- Выраженный дневной провал (до 8% в полдень)
- Вечерний пик в 21:00 (96%)
- Минимальная загрузка в 12:00-14:00




Рис. 5: Средние профили занятости

Кластер 1 (высокая загрузка):

- Средняя занятость: 65.9%
- Умеренный дневной спад (до 19% в 13:00)
- Резкий вечерний рост с пиком в 21:00 (100%)
- Наиболее представительный кластер

Кластер 2 (очень высокая загрузка):

- Средняя занятость: 86.5%
- Относительно равномерная загрузка в течение дня
- Пик смещён на 20:00 (99%)
- Наименьший разброс значений

Кластер 3 (высокая загрузка выходного типа):

- Средняя занятость: 75.0%
- Сглаженный профиль без выраженного дневного спада
- Пик в 21:00 (94%)
- Повышенная дневная загрузка

5.2 Метаданные кластеров (рисунок 6)

Анализ сопутствующих характеристик выявил закономерности:

Распределение дней недели:

- Кластеры 0 и 1 соответствуют будним дням
- Кластеры 2 и 3 соответствуют выходным дням и праздникам

Погодные условия:

- Кластеры 0 и 3 преобладают в ясную погоду (95-96%)
- Кластеры 1 и 2 чаще встречаются при облачной погоде (57-59%)

Температура:

- Кластеры 0 и 3 имеют теплую погоду (в среднем 14-15 градусов)
- Кластеры 1 и 2, наоборот, имеют больше холодных дней (в среднем -1 градус)




Рис. 6: Анализ метаданных кластеров

6 Анализ значимости признаков

6.1 Методология оценки

Для определения влияния признаков на разделение кластеров использованы:

Для категориальных признаков:

- Тест хи-квадрат (χ^2) для таблиц сопряженности
- Сила эффекта Крамера (Cramer's V) для оценки практической значимости

Для числовых признаков:

- Односторонний дисперсионный анализ (ANOVA) при нормальности распределений
- Непараметрический тест Крускала-Уоллиса при нарушениях нормальности
- Мера эффекта η^2 (эта-квадрат) для ANOVA
- Мера эффекта ε^2 (эпсилон-квадрат) для теста Крускала-Уоллиса

6.2 Результаты анализа

Все проанализированные признаки показали статистическую значимость ($p < 0.05$):

Наиболее влиятельные признаки:

1. Признак выходного дня (effect size: 0.828) — сильнейший разделитель
2. Средняя температура (effect size: 0.554) — выраженное сезонное влияние
3. День недели (effect size: 0.541) — структурные недельные паттерны

Умеренно влиятельные признаки:

4. Преобладающий тип погоды (effect size: 0.349)
5. Суммарные просмотры в приложении (effect size: 0.184)
6. Признак праздничного дня (effect size: 0.163)

Все признаки сохраняют практическую ценность для кластеризации и прогнозирования, исключение каких-либо признаков нецелесообразно. Но, возможно, при исключении последних из перечисленных - результат существенно не изменится.

7 Система прогнозирования и тестирование

7.1 Архитектура системы прогнозирования

Разработана двухуровневая система, которая сначала классифицирует тип дня, а затем предоставляет почасовой прогноз:

Уровень 1: Классификация суточного типа (Day Classifier)

На основе метаданных дня система определяет, к какому из четырёх кластеров (суточных паттернов) относится запрашиваемый день. Для этого используется алгоритм на основе правил, выведенных из анализа кластерных характеристик.

Уровень 2: Генерация почасового прогноза (Occupancy Predictor)

После определения кластера система использует соответствующий центроид (средний суточный профиль занятости) в качестве базового прогноза. Центроид содержит 24 значения занятости для каждого часа суток.

7.2 Механизм классификации: взвешенная схема сравнения

Принцип работы

Алгоритм сравнивает метаданные запрашиваемого дня с характеристиками каждого кластера и вычисляет оценку соответствия (score) по четырём критериям. Кластер с наибольшей итоговой оценкой становится предсказанием.

Критерии сравнения и веса:

1. **День недели (вес: 40%)**: Проверяется, входит ли день недели запроса в список наиболее частых дней для кластера. Например, кластер 0 наиболее характерен для будних дней.
2. **Погодные условия (вес: 30%)**: Оценивается совпадение типа погоды с типичными погодными условиями кластера. Кластеры 0 и 3 чаще встречаются в ясную погоду, а кластеры 1 и 2 — в облачную.
3. **Тип дня (вес: 20%)**: Анализируется соответствие по признакам "выходной/праздник". Кластеры 2 и 3 преимущественно состоят из выходных дней, тогда как кластеры 0 и 1 — из будней.
4. **Температурный режим (вес: 10%)**: Проверяется, попадает ли температура в диапазон, характерный для кластера. Вычисляется близость к средней температуре кластера с нормализацией.

Математическая формализация

Для каждого кластера C_i вычисляется итоговая оценка S_i :

$$S_i = \sum_{j=1}^4 w_j \cdot f_j(d, C_i)$$

где:

- w_j — вес j -го критерия ($w_1 = 0.4$, $w_2 = 0.3$, $w_3 = 0.2$, $w_4 = 0.1$)
- d — метаданные запрашиваемого дня
- $f_j(d, C_i)$ — функция соответствия по j -му критерию (0 или 1 для дискретных признаков, нормализованное значение для непрерывных)

Нормализация уверенности

Итоговая уверенность предсказания вычисляется как:

$$\text{Confidence} = \frac{S_{\text{best}} - S_{\text{second}}}{S_{\text{best}}} \times 100\%$$

где S_{best} — оценка лучшего кластера, S_{second} — оценка второго по рейтингу кластера.

Особенности реализации:

- Для каждого кластера предварительно вычислены "правила"— наиболее характерные значения признаков
- Температурная оценка использует нормализованную разницу: $\max(0, 1 - \frac{|T_{\text{day}} - T_{\text{cluster}}|}{20})$
- При равных оценках предпочтение отдаётся более представительному кластеру (с большим количеством дней)

7.3 Генерация почасового прогноза

После определения кластера C_k , система извлекает соответствующий центроид — массив из 24 значений занятости (рисунок 7):

$$P = [p_0, p_1, \dots, p_{23}]$$

где p_h — прогнозируемая занятость в час h (в процентах).

Дополнительные вычисления:

- **Пиковый час:** $\text{peak_hour} = \arg \max_h p_h$
- **Минимальный час:** $\text{min_hour} = \arg \min_h p_h$
- **Средняя занятость:** $\text{avg_occupancy} = \frac{1}{24} \sum_{h=0}^{23} p_h$
- **Рекомендуемые часы:** отсортированные часы с наименьшей занятостью




Рис. 7: Результат прогнозирования на тестовом наборе данных

8 Заключение

Проведённое исследование подтвердило возможность эффективного прогнозирования занятости парковки на основе кластеризации временных рядов. Ключевые достижения:

1. **Методологическая строгость:** Комбинированное использование методов определения оптимального числа кластеров обеспечило обоснованность разделения.
2. **Практическая интерпретируемость:** Выявленные кластеры соответствуют интуитивно понятным паттернам (будни/выходные, погодные условия).
3. **Статистическая обоснованность:** Все используемые признаки показали значимое влияние на разделение кластеров.
4. **Прогностическая ценность:** Разработанная система позволяет с высокой точностью (90-99.9%) предсказывать суточные профили занятости.
5. **Практическая применимость:** Визуализация результатов в форме цветowych гистограмм соответствует требованиям пользовательского интерфейса мобильного приложения.